クラスタリング手法改善提案レポート

作成日: 2026-03-15 **対象**: 需要予測パイプラインにおける距離行列・クラスタリング手法の改善 **基盤実験**: favorita 3パターン比較（v1/v2）、M5 2パターン比較

---

1. 本レポートの目的

本レポートは、favorita（1,782系列）およびM5（30,490系列）の2データセットにわたる計4回の比較実験で得られた知見に基づき、特許出願資料記載のDTWクラスタリングパイプラインにおける**距離行列の計算手法**と**クラスタリング手法**の改善提案を行う。

---

2. 実験結果の総括と問題の特定

2.1 全実験結果の一覧

実験	データ	系列数	P2手法	最適k	Silhouette	P1 WAPE med	P2 WAPE med	P1優位
v1	favorita	1,782	TimeSeriesKMeans(DTW)	2	0.8826	0.5410	0.5805	7%
v1	favorita	1,782	KShape(SBD)	2	0.0596	0.5410	0.5935	10%
v2	favorita	1,782	STL季節成分KMeans	2	0.1075	0.5410	0.5867	8%
M5	M5	30,490	TimeSeriesKMeans(DTW)	2	0.9029	1.3486	1.8443	37%

2.2 特定された3つの構造的問題

問題1: DTW距離が振幅差に支配される

DTW距離空間上では、「高需要系列 vs 低需要系列」の振幅差が最も顕著な分離構造となる。Silhouette Score最大化はこの二分を最適解として選択し、k=2に収束する。

根拠データ	
favorita DTW k=2 Silhouette	0.8826（強い分離）
M5 DTW k=2 Silhouette	0.9029（さらに強い分離）
M5 クラスタ不均衡	98.3% vs 1.7%

k=2で29,984系列と506系列に分割されたM5の結果は、DTWが「振幅の大きさ」のみで系列を二分していることを端的に示す。

問題2: 振幅を除去すると分離構造が消失する

振幅バイアスの問題に対し、v2実験（L2正規化季節成分）とKShape（z正規化+SBD）で振幅を除去したが、いずれもSilhouette Scoreが極めて低くなった。

手法	振幅の扱い	Silhouette (k=2)	解釈
DTW	振幅を保持	0.88	振幅差で明確に分離
STL季節成分KMeans	L2正規化で除去	0.11	微弱な分離のみ
KShape(SBD)	z正規化で除去	0.06	分離構造ほぼなし

これは、振幅を除去した**形状空間上**では明確なクラスタ構造が存在しないことを示唆する。ただし、これは「形状に違いがない」ことを意味するのではなく、以下の要因が考えられる:

- **365次元の次元の呪い**: 高次元ユークリッド空間では距離分布が均一化する（concentration of distances）
- **スパースデータのノイズ**: ゼロ需要が多い系列では、MSTL分解後の季節成分が微小振幅のノイズとなり、正規化後にランダムな方向ベクトルに変換される
- **月次集約の情報損失**: 56-64列の月次データでは、日次レベルの季節パターン差が平滑化される

問題3: DTW距離行列のO(N^2)スケーラビリティ限界

データセット	系列数	DTW距離行列時間	メモリ
favorita	1,782	47s	25MB
M5	30,490	**228.7min**	**7.4GB**
(仮) N=100K	100,000	~41h (推計)	~80GB

O($N^2 \cdot T^2$)のスケーリングにより、N=30Kで約4時間、N=100Kでは推計40時間以上となる。実運用（日次バッチ更新等）では許容できない計算コストである。

---

3. 距離行列の改善提案

3.1 提案: 多解像度特徴ベクトル + ユークリッド距離

概要

DTWが「時系列全体を1つの塊」として距離計算するのに対し、**予測に関連する構成要素を分解して個別に特徴量化**し、低次元ユークリッド空間上でクラスタリングを行う。

特徴ベクトルの設計

```
特徴ベクトル f ∈ R^22 （1系列あたり）

├── 需要水準 (3次元)
```

```
│    ├── log(1 + mean_demand)        振幅情報を対数で圧縮して保持
│    ├── log(1 + std_demand)         変動幅
│    └── zero_ratio                  スパース性（ゼロ需要日の割合）
│
├──── 週次季節パターン (7次元)
│    └── MSTL seasonal_7 最終サイクル（L2正規化）
│      曜日パターンの「形状」
│
├──── 年次季節パターン (10次元)
│    └── MSTL seasonal_365 の FFT振幅 上位10成分（L2正規化）
│      365次元をFFTで圧縮し、主要周期構造を保持
│
└──── トレンド (2次元)
     ├──── 線形トレンド傾き          需要の長期方向
     └──── トレンド曲率（2次多項式係数） 加速/減速パターン
```

各特徴量の設計根拠

特徴量	次元	設計判断	根拠
需要水準	3	v2では振幅を完全除去したが、Silhouette=0.11と分離構造が消失。需要水準は予測に重要な情報であり、除去ではなく**log変換で差を圧縮**して保持すべき	v2実験の失敗
週次季節	7	L2正規化した7次元ベクトル。v2と同一の手法だが、他の特徴量と組み合わせることで相対的な重みが適正化される	MSTL(7,365)の分解構造と整合
年次季節(FFT)	10	v2では365次元の生値を使用し、次元の呪いが発生。**FFT上位10成分**に圧縮することで、主要な年次周期構造（年1回、年2回、年4回等のピーク）を95%以上の分散で保持しつつ35分の1に次元削減	v2の372次元問題の解決
スパース性	(含3)	M5の低需要系列はゼロが大半。DTWはゼロ同士の距離をゼロとして扱い差異を見逃すが、間欠需要 vs 連続需要では予測手法が本質的に異なる	M5のスパースデータ特性
トレンド	2	成長中 vs 減少中 vs 安定の系列では、適切な予測モデルが異なる。傾き+曲率の2パラメータでトレンドの方向と加速度を表現	MSTL分解のトレンド成分活用

計算量の比較

処理	現行（DTW距離行列）	提案（多解像度特徴）
特徴抽出	なし	O(N·T) ≈ M5で~30min
距離行列	$O(N^2 \cdot T^2)$ ≈ **228.7min**	**不要**
クラスタリング	$O(N \cdot k \cdot T^2 \cdot iter)$	O(N·k·d·iter), d=22
メモリ	$O(N^2)$ = **7.4GB**	O(N·d) = **5.4MB**
M5推定合計	~4h	**~30min**

KMeansはユークリッド距離をイテレーション内で逐次計算するため、N×N距離行列の事前計算が不要になる。これにより、処理時間とメモリ使用量の両方で桁違いの改善が見込まれる。

年次季節成分のFFT圧縮の詳細

v2実験で365次元の生値を使用した際の問題を、FFT圧縮がどのように解決するかを示す。

```
入力: seasonal_365 ∈ R^365（MSTL年次季節成分の最終サイクル）

1. FFT適用: S = FFT(seasonal_365) ∈ C^183
2. 振幅スペクトル: A = |S| ∈ R^183
3. 上位10成分を選択: f_annual = A[top_10_indices] ∈ R^10
4. L2正規化: f_annual = f_annual / ||f_annual||

物理的意味:
  A[1]  → 年1回の周期成分の強さ（年間トレンドの振幅）
  A[2]  → 年2回の周期成分の強さ（半年周期: 夏冬の差）
  A[4]  → 年4回の周期成分の強さ（四半期周期）
  A[12] → 年12回の周期成分の強さ（月次パターン）
  A[52] → 年52回の周期成分の強さ（週次の年間変動）
```

365次元 → 10次元への圧縮により、次元の呪いを回避しつつ、年間需要パターンの主要な周波数構造を保持する。

---

4. クラスタリング手法の改善提案

4.1 提案A（最推奨）: 予測ベースk選定

概要

k選定の目的関数を**Silhouette Score（幾何的分離度）→ Validation予測誤差（WAPE）**に変更する。

手順

```
1. 訓練データを再分割:
   train_inner: 訓練データの先頭〜最後30日前
   validation:  訓練データの最後30日

2. for k = k_min ... k_max:
   a. train_inner上の特徴量でクラスタリング（KMeansまたはGMM）
   b. 各クラスタの日次平均系列でMSTL+ETS → validation 30日を予測
   c. SKU変換 → validation_WAPE を計算

3. k* = argmin_k validation_WAPE

4. 選ばれたk*で全訓練データを使って最終クラスタリング → テスト期間の予測
```

根拠

4回の実験で、Silhouette Scoreは一貫してk=2を選択したが、k=2の予測精度はベースライン以下であった。この事実は、**Silhouette Scoreが予測精度と無相関**であることを強く示唆する。

指標	最適化対象	k=2での予測性能
Silhouette Score	クラスタの幾何的分離度	P1に劣後（全実験）
Validation WAPE	**予測誤差そのもの**	**直接最適化**

予測ベースk選定は、クラスタリングの目的関数を「距離空間での分離」から「予測精度の最大化」に再定義するものであり、k=2が本当に予測に最適であれば予測ベースでもk=2が選ばれるはずである。選ばれないなら、Silhouetteが不適切な指標であったことの追加証拠となる。

計算コスト

validation期間を30日とした場合、各kの評価にはクラスタリング + k個のMSTL+ETS予測 + SKU変換のみが必要で、1回あたりのコストは軽微。k_min=5, k_max=50 として46回の評価で、特徴ベースKMeansなら数分で完了する。

4.2 提案B: 二段階クラスタリング

概要

DTWが検出する「需要水準の差」と、v2/KShapeが捉えようとした「形状の差」を**明示的に分離**して二段階で処理する。

手順

```
Stage 1: 需要水準による層化（5群）
├── quantile(mean_demand, q=[0.2, 0.4, 0.6, 0.8]) で5群に分割
├── M5の場合: 各群 ~6,000系列
└── 目的: 振幅バイアスを構造的に除去

Stage 2: 群内での形状クラスタリング（各群で k_shape = 3〜10）
├── z正規化後の特徴ベクトル（需要水準3次元を除外した19次元）でKMeans
├── k_shape は予測ベース（提案A）で群ごとに最適化
└── 目的: 同一需要水準内で季節パターン・トレンドが類似する系列をグルーピング

合計クラスタ数: 5群 × 3〜10 = 15〜50 クラスタ
```

根拠

設計判断	根拠
Stage 1で需要水準を先に層化	DTWがk=2で「需要水準」を分けること自体は合理的。問題はそこで**止まる**こと
Stage 2でz正規化後にクラスタリング	同一需要水準内なら振幅差が小さいため、形状の差が検出可能になる
合計クラスタ数が15-50	k=2の粗さ問題を**構造的に回避**。最低15クラスタが保証される
群内k_shapeを予測ベースで最適化	提案Aとの組み合わせにより、各需要水準層で最適な粒度を選定

この二段階方式は、ドメイン知識（「需要が同じレベルで季節パターンが似ている商品は同じ予測モデルで当たりやすい」）とも整合する。

計算量

処理	現行	二段階方式
Stage 1	—	O(N)（分位数ソートのみ）
Stage 2（各群）	—	O(N/5・k・d・iter) × 5群
合計	$O(N^2 \cdot T^2)$	O(N・k・d・iter)
M5推定時間	~4h	~10min

4.3 提案C: GMM + BICによるモデル選択

概要

KMeansの代わりに**Gaussian Mixture Model (GMM)**を使用し、クラスタ数の選定にBIC（ベイズ情報量規準）を用いる。

根拠

観点	KMeans + Silhouette	GMM + BIC
クラスタ形状	球形のみ	**楕円形**（共分散行列で表現）
k選定の傾向	少ないkを好む（分離度最大化）	データの**複雑さに応じたk**を選ぶ
確率的割当	硬割当（0 or 1）	**軟割当**（各クラスタへの所属確率）
BICの数学的根拠	—	$\mathrm{BIC} = -2\ln L + p\ln N$ （データ適合度とモデル複雑度のバランス）

BICはSilhouetteと異なり、データの対数尤度（適合度）とパラメータ数（複雑度）のバランスを取る情報量規準であり、一般にSilhouetteより**高いk**を選択する傾向がある。22次元の特徴ベクトル空間上で直接適用可能。

---

5. 提案の組み合わせと優先順位

5.1 推奨する組み合わせ

順位	組み合わせ	改善内容	期待効果
1st	多解像度特徴 + 予測ベースk選定	距離行列$O(N^2)$排除 + k=2問題の根本解決	計算10倍以上高速化 + 精度改善

順位	組み合わせ	改善内容	期待効果
2nd	多解像度特徴 + 二段階クラスタリング	距離行列排除 + 粒度の構造的保証	最低15クラスタ保証
3rd	多解像度特徴 + GMM+BIC	距離行列排除 + 情報量規準による柔軟なk選定	球形制約の緩和

5.2 実装の優先順位

優先度	改善項目	単独での効果	実装コスト
最高	多解像度特徴ベクトル（Section 3.1）	DTW距離行列(3.8h)の完全排除、メモリ 7.4GB→5.4MB	中（特徴抽出関数の実装）
最高	予測ベースk選定（Section 4.1）	k=2固定問題の根本解決	低（validation splitの追加のみ）
高	二段階クラスタリング（Section 4.2）	粒度確保の構造的保証（最低15クラスタ）	中（二段階パイプラインの構築）
中	GMM+BIC（Section 4.3）	Silhouetteに代わるモデル選択基準	低（sklearn.mixture.GMMの適用）

多解像度特徴ベクトルと**予測ベースk選定**は独立に実装可能であり、かつそれぞれが最も深刻な問題（スケーラビリティ / k=2固定）を直接解決するため、両方を最高優先度とした。

5.3 改善効果の見積もり

指標	現行（M5 P2）	改善後（見積もり）	改善根拠
処理時間	193.2min + 228.7min DTW	**~30-40min**	DTW距離行列排除 + KMeansの高速化
メモリ	7.4GB (DTW行列)	**~数MB**	N×N行列不要
最適k	2	**15-50**（予測ベース/二段階）	予測誤差直接最適化
WAPE中央値	1.8443	**1.3付近（P1水準）以下**	適切なk粒度での予測精度向上

---

6. 結論

4回の比較実験を通じて、現行パイプラインの2つの構造的問題が特定された:

1. **DTW距離行列のO(N^2)計算コスト** — N=30,490で3.8時間、大規模運用に不適
2. **Silhouette Score最大化によるk=2固定** — データセット・手法横断的に再現され、予測精度と無相関

これらは独立した問題であり、それぞれ**多解像度特徴ベクトル**と**予測ベースk選定**で解決可能である。両方を組み合わせることで、計算コストを桁違いに削減しつつ、クラスタリングの予測精度への貢献を検証できる条件が整う。

特に、予測ベースk選定は現行パイプラインのk選定部分のみの変更で実装でき、**クラスタリングが本当に予測精度を改善できるのか**という根本的な問いに対する回答を得る最も直接的な手段である。